



UNINASSAU

APRENDIZAGEM SUPERVISIONADA E NÃO SUPERVISIONADA

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade


Tipos de Aprendizagem em ML



Aprendizagem Supervisionada

O que é aprendizagem Supervisionada?


Supervised Learning



O que é aprendizagem Supervisionada?


Aprendizagem Supervisionada é uma técnica de machine learning onde um algoritmo aprende a mapear entradas para saídas com base em pares de entrada-saída de exemplo.

- **Como funciona:** O algoritmo é treinado com dados rotulados, onde cada exemplo consiste em um objeto de entrada (vetor) e um valor de saída desejado.
- **Processo:** O algoritmo analisa os dados de treinamento e produz uma função inferida que pode ser usada para mapear novos exemplos.
- **Objetivo:** Generalizar a partir dos dados de treinamento para prever corretamente rótulos de classe para instâncias não vistas anteriormente.



Passos da Aprendizagem Supervisionada

1. **Determinar o tipo de exemplos de treinamento:** Definir que tipo de dados será usado como conjunto de treinamento.
2. **Reunir um conjunto de treinamento representativo:** Coletar objetos de entrada e suas saídas correspondentes.
3. **Determinar a representação das características:** Transformar o objeto de entrada em um vetor de características descritivas.
4. **Escolher a estrutura da função e o algoritmo:** Selecionar o algoritmo apropriado (ex: SVM, árvores de decisão).
5. **Treinar o algoritmo:** Executar o algoritmo no conjunto de treinamento e ajustar parâmetros.
6. **Avaliar a precisão:** Medir o desempenho da função resultante em um conjunto de teste separado.




Escolha do Algoritmo: Fatores Chave

- **Equilíbrio entre Viés e Variância**

Algoritmos com baixo viés são flexíveis, mas podem ter alta variância. É necessário encontrar um equilíbrio para boa generalização.

- **Complexidade da Função e Quantidade de Dados**

Funções complexas requerem mais dados de treinamento e algoritmos mais flexíveis com baixo viés e alta variância.




Escolha do Algoritmo: Fatores Chave

- **Dimensionalidade do Espaço de Entrada**


Alta dimensionalidade pode confundir o algoritmo (maldição da dimensionalidade). Técnicas de redução de dimensionalidade podem ajudar.

- **Ruído nos Valores de Saída**

Dados ruidosos requerem algoritmos que não se ajustem excessivamente aos exemplos de treinamento para evitar overfitting.



Algoritmos Comuns ML



Supervisionado: Classificação x Regressão


Classificação



Classificação: o modelo prevê categorias (saídas qualitativas) a partir de dados de treinamento.

Exemplo: identificar se um paciente está doente ou não com base em exames.

Regressão



Regressão: o modelo prevê valores numéricos (variáveis contínuas).


Exemplo: estimar o salário de uma pessoa a partir da idade e escolaridade.

Algoritmos Comuns de Classificação

Regressão Logística

Modelo linear para classificação binária que estima a probabilidade de uma instância pertencer a uma determinada classe.

Aplicações: Detecção de spam, diagnóstico médico (doença/não doença), previsão de churn de clientes.




Algoritmos Comuns de Classificação

Máquinas de Vetores de Suporte (SVM)

Encontra o hiperplano que melhor separa as classes, maximizando a margem entre os pontos de dados mais próximos.

Aplicações: Classificação de imagens, reconhecimento de escrita manual, bioinformática.




Algoritmos Comuns de Classificação

Árvores de Decisão

Modelos em forma de árvore que dividem os dados em subconjuntos com base em valores de atributos, criando regras de decisão.

Aplicações: Análise de risco de crédito, tomada de decisão em negócios, diagnóstico de falhas.




Algoritmos Comuns de Classificação

k-Vizinhos Mais Próximos (KNN)

Classifica uma instância com base na maioria das classes de seus k vizinhos mais próximos no espaço de características.

Aplicações: Sistemas de recomendação, reconhecimento de padrões, detecção de anomalias.




Algoritmos Comuns de Regressão

Regressão Linear

Modela a relação entre variáveis independentes e uma variável dependente contínua através de uma equação linear, minimizando a soma dos quadrados dos resíduos.

Aplicações: Previsão de preços de imóveis, análise de tendências de vendas, estimativa de consumo de energia.




Algoritmos Comuns de Regressão


Redes Neurais Artificiais

Modelos inspirados no cérebro humano que podem aprender relações complexas e não-lineares entre variáveis de entrada e saída através de múltiplas camadas de neurônios.

Aplicações: Previsão de séries temporais, modelagem de sistemas complexos, estimativa de valores contínuos em problemas multidimensionais.



Aplicações da Aprendizagem Supervisionada



Classificação de Imagens

Reconhecimento de objetos, pessoas, animais ou cenas em imagens digitais, utilizado em sistemas de visão computacional.



Detecção de Spam

Identificação automática de e-mails indesejados com base em características do conteúdo, remetente e outros padrões.



Diagnóstico Médico

Previsão de doenças com base em sintomas, resultados de exames e historico medico, auxiliando profissionais de saúde.

Aplicações da Aprendizagem Supervisionada



Análise de Sentimento

Determinação do tom emocional em textos, útil para análise de feedback de clientes e monitoramento de redes sociais.



Previsão do Tempo



Predição de condições climáticas futuras com base em dados históricos e padrões meteorológicos.

Problemas Comuns e Soluções

Overfitting (Sobreajuste)

O modelo aprende demais dos dados de treinamento e não generaliza bem para novos dados.

- **Validação cruzada**
- **Regularização**
- **Parada precoce**




Problemas Comuns e Soluções


Underfitting (Subajuste)

O modelo é muito simples e não aprende o suficiente dos dados de treinamento.

- **Aumentar a complexidade do modelo**
- **Adicionar mais características**



Underfitting






Overfitting

Problemas Comuns e Soluções

Maldição da Dimensionalidade

Dificuldade em trabalhar com dados de alta dimensionalidade.

- Seleção de características
- Redução de dimensionalidade (PCA, t-SNE)




Problemas Comuns e Soluções

Dados Desbalanceados

Classes com número desigual de exemplos, prejudicando o aprendizado.



- Reamostragem (oversampling/undersampling)
- Ponderação de classes



Oversampling e undersampling são técnicas para lidar com dados desbalanceados em Machine Learning, onde uma classe tem muito mais exemplos que outra.

Problemas Comuns e Soluções

Dados Desbalanceados



- **Oversampling** aumenta a quantidade de exemplos da classe minoritária, gerando novos dados sintéticos (com técnicas como SMOTE) ou duplicando exemplos existentes.
- **Undersampling** reduz a quantidade de exemplos da classe majoritária, eliminando aleatoriamente ou identificando dados menos importantes.

Aprendizagem Não Supervisionada


O que é aprendizagem Supervisionada?

Unsupervised Learning

INPUT RAW DATA




Interpretation




- Unknown Output
- No Training Data Set


Algorithm



Processing



OUTPUT




MODEL TRAINING



O que é Aprendizagem Não Supervisionada?

Aprendizagem Não Supervisionada é uma técnica de machine learning onde os algoritmos aprendem padrões exclusivamente a partir de dados não rotulados, sem orientação prévia.

- **Como funciona:** O algoritmo busca por si mesmo relações, similaridades e estruturas nos dados, sem conhecimento prévio das saídas corretas.
- **Processo:** Identifica padrões naturais e agrupa dados com características semelhantes, descobrindo estruturas ocultas.
- **Objetivo:** Encontrar estruturas significativas nos dados, reduzir dimensionalidade ou agrupar dados similares sem orientação externa.




Aprendizagem Supervisionada x Não Supervisionada


Característica	Supervisionada	Não Supervisionada
Dados	Rotulados	Não rotulados
Objetivo	Prever resultados com base em exemplos	Descobrir padrões e estruturas ocultas
Feedback	Orientado por resultados conhecidos	Sem feedback externo
Tarefas	Classificação, regressão	Clustering, redução de dimensionalidade
Complexidade	Geralmente mais simples	Geralmente mais complexa
Aplicações	Previsão de preços, classificação de e-mails	Segmentação de clientes, detecção de anomalias



Supervised vs. Unsupervised Learning



Supervised learning




Unsupervised learning

Tipos de Problemas Resolvidos

Agrupamento (Clustering)

Organiza dados em grupos (clusters) com base em similaridades, identificando estruturas naturais nos dados.

Aplicações: Segmentação de clientes, agrupamento de documentos, análise de imagens.




Tipos de Problemas Resolvidos

Redução de Dimensionalidade

Simplifica dados de alta dimensão mantendo as informações essenciais, facilitando visualização e análise.

Exemplos: Visualização de dados complexos, pré-processamento para outros algoritmos.




Tipos de Problemas Resolvidos

Associação

Descobre regras que descrevem relações significativas entre variáveis em grandes conjuntos de dados.

Exemplos: Análise de cesta de compras, recomendação de produtos, descoberta de padrões.




Algoritmos Comuns de Agrupamento (Clustering)


K-Means

Agrupa dados em K clusters com base na distância aos centróides, que são iterativamente ajustados para minimizar a variância dentro de cada grupo.

Aplicações: Segmentação de clientes, compressão de imagens, agrupamento de documentos.



Before K-Means




After K-Means

Algoritmos Comuns de Agrupamento (Clustering)

Agrupamento Hierárquico

Constrói uma hierarquia de clusters (dendrograma) usando abordagens aglomerativas (bottom-up) ou divisivas (top-down).

Aplicações: Taxonomias biológicas, análise de redes sociais, classificação de documentos.




Algoritmos Comuns de Agrupamento (Clustering)

DBSCAN




Density-Based Spatial Clustering of Applications with Noise. Agrupa pontos com base na densidade, identificando clusters de formato arbitrário e detectando outliers.

Aplicações: Detecção de anomalias, análise espacial, reconhecimento de padrões em dados com ruído.

KMeans



DBSCAN




Algoritmos Comuns de Redução de Dimensionalidade

Análise de Componentes Principais (PCA)

Transforma os dados em um novo conjunto de variáveis não correlacionadas (componentes principais), ordenadas pela quantidade de variância que explicam.

Aplicações: Visualização de dados, compressão de imagens.




Algoritmos Comuns de Redução de Dimensionalidade

t-SNE


Técnica de visualização que reduz dados de alta dimensão para 2 ou 3 dimensões, preservando as relações de vizinhança entre os pontos.

Aplicações: Visualização de clusters, análise exploratória de dados.



Aplicações da Aprendizagem Não Supervisionada

Segmentação de Clientes



Segmentação de Clientes


Agrupamento de clientes com comportamentos de compra similares para estratégias de marketing personalizadas e recomendações de produtos



Deteccção de Anomalias

Identificação de padrões incomuns em dados, util para detecção de fraudes em transações financeiras e monitoramento de sistemas

Aplicações da Aprendizagem Supervisionada



Análise de Redes Sociais

Identificação de comunidades e grupos de influência em redes sociais para entender dinâmicas de interação e disseminação de informações



Análise Genômica

Agrupamento de genes com padrões de expressão similares para descoberta de funções biológicas e desenvolvimento de tratamentos médicos



Análise de Cesta de Compras

Descoberta de associações entre produtos frequentemente comprados juntos para otimização de layout de lojas e promoções


Desafios e Considerações

Interpretabilidade

Os padrões descobertos podem ser difíceis de interpretar e explicar, especialmente em dados de alta dimensionalidade.

Avaliação de Resultados

Sem rótulos de referência, é difícil avaliar objetivamente a qualidade dos agrupamentos ou padrões encontrados.




Desafios e Considerações

Escolha de Parâmetros

Determinar o número ideal de clusters ou a configuração de hiperparâmetros sem orientação externa é um desafio significativo.

Escala e Dimensionalidade

Algoritmos não supervisionados podem ter alto custo computacional em grandes volumes de dados ou sofrer com a "maldição da dimensionalidade".



Interstellar (2014)



As reservas naturais da Terra estão chegando ao fim e um grupo de astronautas recebe a missão de verificar possíveis planetas para receberem a população mundial, possibilitando a continuação da espécie. Cooper é chamado para liderar o grupo e aceita a missão sabendo que pode nunca mais ver os filhos. Ao lado de Brand, Jenkins e Doyle, ele seguirá em busca de um novo lar.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code