






UNINASSAU

REDUÇÃO DE DIMENSIONALIDADE

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

A Maldição da Dimensionalidade




A maldição da dimensionalidade refere-se à relação inversa entre o aumento das dimensões de um modelo e a redução da capacidade de generalização. À medida que o número de variáveis aumenta, o espaço do modelo cresce exponencialmente, tornando os dados esparsos (conjuntos de dados em que a grande maioria dos elementos são zeros ou valores padrão).



A Maldição da Dimensionalidade

Problemas Associados:


- **Esparsidade dos dados:** A maior parte do espaço fica vazia, sem pontos de dados observáveis
- **Aumento do tempo computacional:** Mais dimensões exigem mais processamento
- **Overfitting:** Modelos podem superajustar os dados de treinamento
- **Multicolinearidade:** Variáveis redundantes ou correlacionadas dificultam a interpretabilidade



O que a Redução da Dimensionalidade?

O que é Redução de Dimensionalidade

Redução de Dimensionalidade é o processo de reduzir o número de variáveis de entrada (atributos) em um conjunto de dados, preservando o máximo possível de informações importantes.




Benefícios da Redução de Dimensionalidade

- **Simplificação de Modelos**

Reduz a complexidade dos modelos de machine learning, tornando-os mais fáceis de entender e interpretar. Modelos mais simples são menos propensos a erros e mais eficientes.

- **Melhoria da Interpretabilidade**

Com menos dimensões, é mais fácil visualizar e compreender os dados. A interpretabilidade é crucial para validar resultados e tomar decisões informadas.




Benefícios da Redução de Dimensionalidade

- **Redução do Tempo de Treinamento**

Menos variáveis significam menos cálculos, resultando em treinamento mais rápido dos algoritmos. Isso é especialmente importante em grandes conjuntos de dados.

- **Mitigação de Overfitting**

Ao remover variáveis redundantes ou ruidosas, a redução de dimensionalidade ajuda a prevenir o superajuste, melhorando a capacidade de generalização do modelo para novos dados.



Tipos de Redução de Dimensionalidade

Features

As **features (ou características)** são as propriedades ou atributos individuais e mensuráveis de um conjunto de dados. Elas são as variáveis de entrada que um modelo usa para aprender padrões e fazer previsões.

The diagram illustrates a dataset table with four rows and five columns. The columns are labeled 'Size', 'Beds', 'Baths', 'Zip', and 'Price'. The first four columns are grouped under the label 'Features', and the last column is labeled 'Label'. The rows are grouped under the label 'Rows', and the columns are grouped under the label 'Columns'.

	Features				Label
Rows	Size	Beds	Baths	Zip	Price
	1100	1	1	64576	1.29
	1900	3	1.5	78321	2.14
	2800	3	3	98712	3.10
	3400	4	3.5	25721	3.75
Columns					

Seleção de Features


Tipos de Redução de Dimensionalidade

Seleção de Features

Escolha de um subconjunto das features originais do conjunto de dados, mantendo apenas as variáveis mais relevantes e descartando as demais.

Métodos Principais:

- **Métodos de Filtro:** Avaliam a relevância das features independentemente do modelo
- **Métodos de Wrapper:** Usam o desempenho do modelo para selecionar features
- **Métodos Embarcados:** Seleção integrada ao processo de treinamento do modelo




Métodos de Filtro (Filter Methods)


Os Métodos de Filtro avaliam a relevância das features independentemente do modelo de machine learning. Eles utilizam propriedades intrínsecas das features e medidas estatísticas para classificar e selecionar as features mais relevantes antes do treinamento do modelo.

Como Funciona?

- Os métodos de filtro aplicam testes estatísticos para avaliar a relação entre cada feature e a variável alvo. As features são ranqueadas de acordo com suas pontuações estatísticas, e as features com pontuações mais altas são selecionadas. Este processo ocorre antes do treinamento do modelo, tornando-o muito eficiente.



Métodos de Filtro (Filter Methods)



Características Principais:

- Rápidos e eficientes
- Independentes do algoritmo
- Usam testes estatísticos
- Escaláveis para grandes datasets

Vantagens:

Rápido, escalável, independente do modelo, ideal para pré-processamento inicial

Desvantagens:


Não considera interações entre features, pode ignorar features importantes em combinação

Métodos de Wrapper


Os métodos wrapper usam o desempenho do modelo para selecionar features. Eles treinam o modelo com diferentes combinações de features e avaliam qual combinação produz o melhor desempenho, considerando as interações entre as features.

Como Funciona?

1. Seleciona um subconjunto de features
2. Treina o modelo com esse subconjunto
3. Avalia o desempenho do modelo
4. Adiciona ou remove features baseado no desempenho
5. Repete até atingir critério de parada



Métodos de Wrapper



Características Principais:

- **Forward Selection:** Inicia com conjunto vazio e adiciona features iterativamente até não haver melhoria
- **Backward Elimination:** Inicia com todas as features e remove iterativamente as menos significativas
- **Recursive Feature Elimination (RFE):** Remove recursivamente features menos importantes até atingir o número desejado

Vantagens:

Otimização específica para o modelo, considera interações entre features, geralmente resulta em melhor desempenho

Desvantagens:


Computacionalmente caro, risco de overfitting, não escalável para grandes datasets

Métodos Embarcados (Embedded Methods)


Os métodos embarcados realizam a seleção de features **durante o processo de treinamento do modelo**. A seleção é integrada ao algoritmo de aprendizado, combinando as vantagens dos métodos de filtro e wrapper.

Diferencial dos Métodos Embarcados:

Ao contrário dos métodos de filtro (que selecionam antes do treinamento) e wrapper (que testam combinações separadamente), os métodos embarcados aprendem quais features contribuem mais para o modelo enquanto o modelo está sendo treinado, tornando o processo mais eficiente.



Métodos Embarcados (Embedded Methods)



Técnicas Principais:

- L1 Regularization (Lasso)
- Adiciona penalidade proporcional ao valor absoluto dos coeficientes, forçando alguns a zero e eliminando features
- Decision Trees e Random Forests
- Seleccionam features mais importantes para divisão de nós baseado em critérios como Gini ou ganho de informação
- Gradient Boosting
- Prioriza features que reduzem o erro mais efetivamente durante a construção das árvores

Vantagens:

- Eficiente e eficaz
- Aprende features relevantes durante treinamento
- Menos propenso a overfitting que wrapper
- Bom equilíbrio entre velocidade e precisão

Limitações

- Limitado a algoritmos que suportam essa funcionalidade
- Menos interpretável que métodos de filtro
- Específico para cada tipo de modelo

Extração de Features

Tipos de Redução de Dimensionalidade

Extração de Features

Transformação das features originais em um novo conjunto de features de menor dimensão, criando novas variáveis que capturam a essência dos dados.

Técnicas Principais:


- **PCA (Principal Component Analysis):**
Método linear não supervisionado
- **LDA (Linear Discriminant Analysis):**
Método linear supervisionado
- **t-SNE:** Método não linear para visualização



Tipos de Redução de Dimensionalidade

Extração de Features


No mundo do aprendizado de máquina, a extração de recursos é parte integrante da otimização de modelos — ela gera dados significativos e relevantes, ajudando posteriormente a aumentar a eficiência e a precisão desses modelos.



Tipos de Redução de Dimensionalidade


Extração de Features

No mundo do aprendizado de máquina, a extração de recursos é parte integrante da otimização de modelos — ela gera dados significativos e relevantes, ajudando posteriormente a aumentar a eficiência e a precisão desses modelos.



Um exemplo de extração de Features


Considere uma IA de reconhecimento de imagem projetada para identificar árvores em fotografias. A extração de características pode envolver ensinar o modelo a procurar certas cores (como verde e marrom), formas (como redondas e alongadas) e texturas (como a aspereza da casca ou a suavidade das folhas).



Fonte: Viso Suite


Importância de Extração de Features em ML

- **Redução da Dimensionalidade:** A extração de características ajuda a reduzir a dimensionalidade do conjunto de dados . Isso se traduz em processos de modelagem menos complexos, mais rápidos e mais eficientes.
- **Melhorando o desempenho do modelo:** ao omitir recursos irrelevantes, os modelos podem se concentrar em informações pertinentes, o que leva a melhor desempenho e precisão.



Extração de Features é fundamental em ML

- **Redução de Ruído:** Extrair características salientes pode ajudar a reduzir o ruído no conjunto de dados. Com menos ruído, o modelo pode tomar decisões com base em dados limpos e claros.
- **Compreendendo os Dados:** A extração de características pode ajudar a compreender melhor o conjunto de dados, esclarecendo seus aspectos cruciais. Ela ajuda a destacar as relações entre os vários elementos de dados.




Análise de Componentes Principais (PCA)

O **PCA (Principal Component Analysis)** é o método de redução de dimensionalidade mais amplamente utilizado. É uma técnica linear de extração de features que combina e transforma as features originais para produzir novas características chamadas componentes principais.

Como Funciona?

- Identifica componentes principais (novas variáveis não correlacionadas)
- Maximiza a variância dos dados projetados
- Realiza transformação linear da matriz de covariância
- Utiliza autovetores e autovalores para determinar os componentes
- Projeta os dados em um novo espaço de menor dimensão



Aplicações Práticas:


Redução de ruído, visualização de dados complexos, pré-processamento para outros algoritmos de machine learning, compressão de imagens e análise exploratória de dados.

Análise Discriminante Linear (LDA)

A **Análise Discriminante Linear (LDA)** é uma técnica linear de extração de features e um método supervisionado. Diferente do PCA, a LDA utiliza os rótulos de classificação para projetar os dados em um novo espaço de menor dimensão.

Objetivo Principal

Maximizar a separação entre classes diferentes enquanto minimiza a variância dentro de cada classe, criando uma representação que facilita a classificação.



Aplicações Práticas:

- Reconhecimento facial
- Diagnóstico médico
- Análise de crédito
- Reconhecimento de padrões


Análise Discriminante Linear (LDA)

Como funciona?

A LDA utiliza a Matriz de Dispersão (Scatter Matrix) em vez da matriz de covariância usada pelo PCA. O algoritmo computa combinações lineares das features originais que correspondem aos maiores autovalores da matriz de dispersão.


Características Principais:

- Maximiza a distância entre as médias das classes
- Minimiza a dispersão (variância) dentro de cada classe
- Requer rótulos de classe para o treinamento
- Ideal para problemas de classificação




Matriz de Dispersão (Scatter Matrix)

PCA vs LDA




Aspecto	PCA	LDA
Tipo	Não supervisionado	Supervisionado
Objetivo	Maximizar variância	Separar classes
Usa rótulos	Não	Sim
Aplicação	Visualização, compressão	Classificação

Mesmo Objetivo, Caminhos Diferentes



t-SNE (t-distributed Stochastic Neighbor Embedding)



Aplicações:

Visualização de dados complexos, identificação de clusters, exploração de padrões ocultos em conjuntos de dados de alta dimensionalidade, análise exploratória de dados.

O **t-SNE** é um método não linear de redução de dimensionalidade, predominantemente utilizado para visualização de dados complexos de alta dimensão.

Como Funciona:

- Preserva a estrutura local dos dados
- Pontos próximos no espaço original permanecem próximos no espaço reduzido
- Utiliza um kernel Gaussiano para calcular similaridade entre pares de pontos
- Projeta dados para 2 ou 3 dimensões para visualização

Comparação entre PCA, LDA e t-SNE

Característica	PCA	LDA	t-SNE
Tipo de Método	Linear	Linear	Não Linear
Aprendizado	Não Supervisionado	Supervisionado	Não Supervisionado
Objetivo Principal	Maximizar a variância dos dados projetados	Maximizar a separação entre classes e minimizar variância intraclasses	Preservar a estrutura local dos dados
Dimensões de Saída	Flexível (1 a n-1 dimensões)	Limitado a (k-1) dimensões, onde k = número de classes	Geralmente 2 ou 3 dimensões
Casos de Uso	Redução de ruído, pré-processamento, compressão de dados	Classificação, reconhecimento de padrões	Visualização de dados complexos, exploração de clusters
Requer Rótulos	Não	Sim	Não
Velocidade	Rápido	Rápido	Lento (computacionalmente intensivo)

Estudo de Caso

Projeto de Redução de Dimensionalidade em Imagens [5]

- **Descrição:** O projeto de Redução de Dimensionalidade em Imagens tem como objetivo implementar algoritmos básicos para transformar imagens coloridas em representações mais simples e compactas. Utilizando Python, o projeto consiste em duas etapas principais: conversão para tons de cinza e binarização.
- Na primeira etapa, a imagem colorida é convertida para tons de cinza, resultando em uma representação em escala de cinza que mantém as informações de luminosidade, mas descarta as informações de cor. Isso é feito aplicando uma combinação linear dos canais de cor RGB, onde o canal vermelho (R), o canal verde (G) e o canal azul (B) contribuem com diferentes pesos para formar o tom de cinza correspondente a cada pixel.

Imagem Original



Imagem em Tons de Cinza



Imagem Binarizada



Projeto de Redução de Dimensionalidade em Imagens

- Na segunda etapa, a imagem em tons de cinza é binarizada, transformando-a em uma imagem preto e branco onde cada pixel é atribuído como preto ou branco com base em um determinado limiar de intensidade. Pixels com intensidade abaixo do limiar são considerados pretos, enquanto pixels com intensidade acima ou igual ao limiar são considerados brancos.
- O projeto inclui a implementação dessas etapas utilizando apenas bibliotecas básicas do Python, sem depender de bibliotecas especializadas para processamento de imagens. Além disso, é fornecida uma visualização das imagens originais, em tons de cinza e binarizadas, para facilitar a compreensão do processo de redução de dimensionalidade realizado.

Imagem Original



Imagem em Tons de Cinza



Imagem Binarizada



A Garota Artificial (2022)



Uma equipe de agentes especiais descobre um novo programa de computador revolucionário para atrair e prender predadores online. Depois de se juntarem ao problemático desenvolvedor do programa, eles logo descobrem que a IA está avançando rapidamente além de seu propósito original.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679
3. CONCEITOS.tech. O que são features em Machine Learning e como selecioná-las. Disponível em: <https://conceitos.tech/tutoriais/inteligencia-artificial/machine-learning/o-que-sao-features-em-machine-learning-e-como-seleciona-las/>. Acesso em: 13 out. 2025.
4. BOTPENGUIN. Feature Extraction [online]. Disponível em: <https://botpenguin.com/glossary/feature-extraction>. Acesso em: 13 out. 2025.
5. RANDÃO, Natasha B. Formação Machine Learning Specialist: Redução de Dimensionalidade em Imagens para Redes Neurais. GitHub. Disponível em: <https://github.com/NatashaB-randao/Formacao-Machine-Learning-Specialist/tree/main/Desafios/Redu%C3%A7%C3%A3o%20de%20Dimensionalidade%20em%20Imagens%20para%20Redes%20Neurais>. Acesso em: 13 out. 2025.

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code