



UNINASSAU

MODELOS PARAMÉTRICOS E NÃO PARAMÉTRICOS

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

O que é um modelo em ML?

Um modelo é uma função que tenta **aproximar uma relação entre variáveis de entrada e saída**:

$$\hat{Y} = f(X; \theta)$$

$X \rightarrow$ vetor de entradas (features)

$\hat{Y} \rightarrow$ saída estimada

$\theta \rightarrow$ parâmetros aprendidos (pesos, coeficientes, etc.)

O objetivo é ajustar θ para minimizar o erro entre $\hat{Y}$ e o valor real Y .


Classificação Geral dos Modelos

Tipo de Modelo	Definição	Características Principais	Exemplos Clássicos	Aplicações Comuns
Paramétrico	Assume uma forma funcional fixa para o modelo (ex: linear, polinomial).	- Número fixo de parâmetros. - Menor flexibilidade. - Treinamento rápido. - Requer menos dados.	- Regressão Linear - Regressão Logística - Naive Bayes - Perceptron	- Previsão de preços - Classificação binária simples - Modelos explicáveis
Não Paramétrico	Não assume uma forma fixa; a estrutura do modelo depende dos dados.	- Número de parâmetros aumenta com os dados. - Alta flexibilidade. - Maior custo computacional. - Requer mais dados.	- K-Nearest Neighbors (KNN) - Árvores de Decisão - Random Forest - SVM com kernel não linear	- Classificação complexa - Reconhecimento de padrões - Análise não linear de dados

Modelo Paramétrico

O que é um Modelo Paramétrico?

Um modelo paramétrico é aquele que **assume que a função f tem uma forma funcional predefinida e conhecida**. O trabalho de estimar f é reduzido ao trabalho de estimar um **número fixo de parâmetros (coeficientes)** a partir dos dados de treinamento.




Exemplo: Regressão Linear

Suponha que você acredita que a relação entre X e Y é **linear**. Então, você assume a seguinte forma:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

Agora, em vez de estimar a função f inteira, você precisa apenas estimar os **parâmetros** $\beta_0, \beta_1, \beta_2, \dots, \beta_n$. Isso é muito mais simples e rápido!



Vantagens e Desvantagens dos Modelos Paramétricos

VANTAGENS


- ✓ Interpretação simples
- ✓ Menos dados necessários
- ✓ Treinamento rápido
- ✓ Boa generalização quando a hipótese é adequada

DESVANTAGENS


- ✗ Estrutura fixa (pouca flexibilidade)
- ✗ Não captura relações complexas
- ✗ Sensível a outliers
- ✗ Risco de underfitting

Exemplos Clássicos

Exemplos de Modelos Paramétricos




Regressão Linear



Regressão Logística



Naive Bayes



Perceptron

Regressão Linear

Assume uma relação linear entre as variáveis de entrada e a saída. Define a relação como uma combinação linear dos coeficientes β .

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \epsilon$$

Eixo X $\rightarrow$ variável x

Eixo Y $\rightarrow$ variável y


Reta $\rightarrow \beta_0 + \beta_1 X_1$

Distâncias entre pontos e reta (Erro) $\rightarrow \epsilon$

O modelo paramétrico define uma **função linear fixa** com parâmetros β_0 e β_1

O aprendizado consiste em **ajustar esses parâmetros** para que a reta se aproxime ao máximo dos dados reais, minimizando o erro ϵ .

Regressão Linear



Regressão Logística

Assume uma forma logística para a probabilidade de um evento.
Transforma a saída linear em probabilidades entre 0 e 1.

$$P(Y = 1 | X) = \frac{1}{1 + e^{-z}}$$

$$\text{Como } z = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n$$

$P(Y=1 | X) \rightarrow$ Probabilidade do evento ocorrer

$z \rightarrow$ Combinação linear dos dados e parâmetros


$e \rightarrow$ Base da função exponencial

$e^{-z} \rightarrow$ Garante que o resultado fique entre 0 e 1

$\beta_i \rightarrow$ Pesos ajustados pelo modelo

$X_i \rightarrow$ Variáveis de entrada

Regressão Logística



Naive Bayes


Usa o Teorema de Bayes com suposição de independência entre variáveis.

$$P(A/B) = \frac{P(B/A) \times P(A)}{P(B)}$$

Onde:

- A: hipótese
- D: dados observados
- P(A): probabilidade a priori
- P(B/A): verossimilhança
- P(A/B): probabilidade a posteriori

Perceptron




- Modelo linear com pesos w_i e bias.
- Saída depende da função de ativação.
- Base de redes neurais modernas

Modelos Não Paramétricos


O que é um Modelo Não Paramétrico?

Um modelo não paramétrico é um tipo de modelo estatístico e de aprendizado de máquina que **não faz suposições rígidas sobre a forma da distribuição dos dados ou sobre um conjunto finito de parâmetros.**



O que é um Modelo Não Paramétrico?

- Não assumem forma funcional.
- Aprendem a estrutura diretamente dos dados.
- A complexidade cresce com o número de amostras.



Vantagens x Desvantagens (Não Paramétricos)

Vantagens e Desvantagens (Não Paramétricos)



Vantagens

- Alta flexibilidade
- Boa capacidade de adaptação




Desvantagens


- Maior custo computacional
- Requerem mais dados
- Sofrem com overfitting

Exemplos de Modelos Não Paramétricos


Exemplos de Modelos Não Paramétricos



**KNN (K-Nearest
Neighbors)**



Árvores de Decisão



Random Forest




SVM com kernel

k-NN (K-Nearest Neighbors)

"k-NN" é a sigla para K-Nearest Neighbors (KNN), que significa "K vizinhos mais próximos" em português


- Cada cor = uma classe.
- As fronteiras são moldadas pelos dados.
- A decisão depende dos vizinhos mais próximos.



Árvores de Decisão


Árvores de decisão são **diagramas hierárquicos que visualizam uma série de escolhas**, seus resultados e probabilidades, usadas para tomada de decisão, análise de risco e para treinar algoritmos de aprendizado de máquina em tarefas de classificação e regressão.

- Estrutura hierárquica de decisões.
- Divide o espaço com base em métricas (Gini, entropia).



Random Forest

Random forest é um algoritmo de aprendizado de máquina amplamente utilizado, registrado por Leo Breiman e Adele Cutler, que **combina a saída de múltiplas decision trees para alcançar um único resultado**. Sua facilidade de uso e flexibilidade impulsionaram sua adoção, pois lida com problemas de classificação e regressão.




SVM com kernel

Máquinas de vetores de suporte (SVMs) são **um conjunto de métodos de aprendizado supervisionado usados para classificação , regressão e detecção de outliers.**

As vantagens das máquinas de vetores de suporte são:

- Eficaz em espaços de alta dimensão.
- Ainda eficaz em casos onde o número de dimensões é maior que o número de amostras.
- Usa um subconjunto de pontos de treinamento na função de decisão (chamados vetores de suporte), por isso também é eficiente em termos de memória.
- Versátil: diferentes funções de kernel podem ser especificadas para a função de decisão. Kernels comuns são fornecidos, mas também é possível especificar kernels personalizados.



Exemplo

Exemplo: Prevendo a altura de pessoas [6]

Imagine que temos os seguintes dados:

Idade (anos)	Altura (cm)
5	110
10	140
15	165
20	175
25	178
30	178
40	178
45	178

Queremos prever a altura de uma pessoa com base na idade. Vamos usar dois modelos:

1. Paramétrico: Regressão Linear.
 - Assumiremos que existe uma relação linear entre idade e altura.
2. Não Paramétrico: K-Nearest Neighbors (KNN).
 - Permitiremos que o modelo encontre padrões diretamente nos dados, sem suposições.

Exemplo: Prevendo a altura de pessoas

Passo 1: Visualizando os Dados

Vamos plotar os pontos para entender o comportamento.

```
import numpy as np
import matplotlib.pyplot as plt


# Dados de exemplo
idade = np.array([5, 10, 15, 20, 25, 30, 40, 45])
altura = np.array([110, 140, 165, 175, 178, 178, 178, 178])

# Plot
plt.scatter(idade, altura, color='blue', label='Dados Observados')
plt.xlabel('Idade (anos)')
plt.ylabel('Altura (cm)')
plt.title('Altura vs Idade')
plt.legend()
plt.show()
```

Exemplo: Prevendo a altura de pessoas

Passo 1: Visualizando os Dados

Vamos plotar os pontos para entender o comportamento.



Esse gráfico mostra que a altura cresce rápido na infância, estabilizando-se na idade adulta.

Exemplo: Prevendo a altura de pessoas

Passo 2: Modelo Paramétrico (Regressão Linear)

A regressão linear ajustará uma **linha reta** aos dados, assumindo uma relação fixa.

```
from sklearn.linear_model import LinearRegression

# Regressão Linear
idade = idade.reshape(-1, 1) # Transformando para matriz
modelo_parametrico = LinearRegression()
modelo_parametrico.fit(idade, altura)


# Previsão
idade_teste = np.array([8, 18, 25, 30, 40, 45]).reshape(-1, 1) # Testando idades fora da amostra
previsoes_parametricas = modelo_parametrico.predict(idade_teste)

# Plot
plt.scatter(idade, altura, color='blue', label='Dados Observados')
plt.plot(idade, modelo_parametrico.predict(idade), color='red', label='Regressão Linear')
plt.scatter(idade_teste, previsoes_parametricas, color='green', label='Previsões')
plt.xlabel('Idade (anos)')
plt.ylabel('Altura (cm)')
plt.title('Modelo Paramétrico - Regressão Linear')
plt.legend()
plt.show()
```

Exemplo: Prevendo a altura de pessoas

Passo 2: Modelo Paramétrico (Regressão Linear)

A regressão linear ajustará uma **linha reta** aos dados, assumindo uma relação fixa.



Resultados:

O modelo linear cria uma linha reta que tenta generalizar o comportamento dos dados. Porém, para idades muito altas (ex.: 30 anos), a previsão pode ser imprecisa porque o crescimento já estabilizou.

Exemplo: Prevendo a altura de pessoas

Passo 3: Modelo Não Paramétrico (KNN)

Com o KNN, o modelo usará as alturas dos vizinhos mais próximos para prever novas idades

```
from sklearn.neighbors import KNeighborsRegressor

# KNN
modelo_nao_parametrico = KNeighborsRegressor(n_neighbors=2) # Usando 2 vizinhos
modelo_nao_parametrico.fit(idade, altura)


# Previsão
previsoes_nao_parametricas = modelo_nao_parametrico.predict(idade_teste)

# Plot
plt.scatter(idade, altura, color='blue', label='Dados Observados')
plt.scatter(idade_teste, previsoes_nao_parametricas, color='orange', label='Previsões')
plt.xlabel('Idade (anos)')
plt.ylabel('Altura (cm)')
plt.title('Modelo Não Paramétrico - KNN')
plt.legend()
plt.show()
```

Exemplo: Prevendo a altura de pessoas

Passo 3: Modelo Não Paramétrico (KNN)

Com o KNN, o modelo usará as alturas dos vizinhos mais próximos para prever novas idades



Resultados:

O KNN prevê a altura baseando-se nas idades mais próximas no dataset. Ele não assume nenhuma forma fixa e adapta-se melhor a padrões complexos, mas pode ser sensível a ruídos nos dados.

Exemplo: Prevendo a altura de pessoas

Conclusão:

Tanto os modelos paramétricos quanto os não paramétricos têm seus pontos fortes e fracos. A compreensão das diferenças entre eles é necessária para escolher o modelo mais adequado para cada tarefa de Machine Learning ou análise estatística. Não existe uma “melhor” abordagem universal; a escolha depende do contexto específico do problema e das características dos dados disponíveis. Em muitos casos, a experimentação com diferentes tipos de modelos é a melhor maneira de determinar qual deles oferece o melhor desempenho.

2001: Uma Odisseia no Espaço (1968)



Considerado por muitos como o melhor e mais importante filme de ficção científica da história, 2001: Uma Odisseia no Espaço é dirigido por Stanley Kubrick e explora diferentes temas, como tecnologia, vida extraterrestre, viagem espacial, evolução humana e, claro, inteligência artificial. A história acompanha uma expedição de astronautas em busca por evidências de que o ser humano não está sozinho. A obra cinematográfica, lançada em 1968, ganhou o Oscar de Efeitos Visuais e foi indicada também às categorias de Diretor, Roteiro Original e Direção de Arte.

2001 é um verdadeiro marco para a história do cinema e está disponível no catálogo do HBO Max. O indiscutível impacto da história de Kubrick (co-escrita por Arthur C. Clarke) é representado nas notas dos sites de crítica. No IMDb, a produção foi avaliada em 8.3, já no Metacritic teve 84 entre a crítica especializada e 8.2 entre o público. No Rotten Tomatoes, a aprovação foi de 91% e 89%, respectivamente.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679
3. BISHOP, C. Pattern Recognition and Machine Learning. Springer, 2006.
4. HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. The Elements of Statistical Learning. Springer, 2009.
5. GERON, A. Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. O'Reilly, 2023.
6. Lucas, H. B. "O que são Modelos Paramétricos e Não Paramétricos em machine learning". IA Com Café, 27 jan. 2025. Disponível em: <https://iacomcafe.com.br/modelos-parametricos-nao-parametricos/>. Acesso em: 26 out. 2025.

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code