




UNINASSAU

ÁRVORES DE DECISÃO

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

O que são Árvores de Decisão?

Árvores de decisão são diagramas hierárquicos que visualizam etapas, decisões e resultados possíveis, utilizadas tanto para problemas de negócios quanto para machine learning (classificação e regressão). Elas funcionam como um fluxograma que divide um conjunto de dados com base em condições, e são compostas por nós (de decisão, probabilidade e folha), ramos e terminações, permitindo uma análise visual clara de cenários complexos.



O que são Árvores de Decisão?

Uma Árvore de Decisão é como um caminho de escolhas que nos ajuda a tomar decisões com base em informações. Imagine que você é um médico e tem um paciente. Você quer descobrir se esse paciente está doente ou não. É como um fluxograma de perguntas que você faria para chegar a uma conclusão.





Figura 1. Fluxograma de uma árvore de decisão para decidir se um paciente está doente ou não

Por que usar Árvores de Decisão?

- Fácil interpretação
- Lida bem com variáveis numéricas e categóricas
- Pouco sensível à escala
- Serve como base para ensembles (Random Forest, XGBoost)




Estrutura de uma Árvore

Uma árvore de decisão consiste em três tipos de nós:

- **Nó Raiz:** O topo da árvore que corresponde à primeira condição de decisão e contém todos os dados.
- **Nós Internos:** Representam as condições de decisão internas da árvore e contém subconjuntos de dados.
- **Nós Folha:** Representam as decisões finais ou os valores de saída e contém os subconjuntos de dados utilizados para tomar essas decisões.

Estrutura de uma Árvore


- Nó raiz: primeira divisão
- Nós internos: decisões intermediárias
- Nós Folhas: resultados finais



Como as Árvores de Decisão Funcionam?


As árvores de decisão seguem um processo iterativo para dividir os dados de treinamento em subconjuntos cada vez mais puros até que as condições finais de decisão sejam alcançadas.

O algoritmo mais comum para construir árvores de decisão é o CART (Classificação e Regressão Baseadas em Árvores).



O Algoritmo CART

O algoritmo de **Classificação e Regressão Baseado em Árvores (CART)** é a base para a construção de árvores de decisão. Ele opera de maneira iterativa, buscando dividir os dados de treinamento em subconjuntos mais homogêneos, refinando as decisões à medida que percorre a estrutura da árvore. Esse algoritmo pode ter várias abordagens que levarão a construir árvores de classificação ou de regressão.



O Algoritmo CART: Classificação

Para tarefas de classificação, o critério de Gini é comumente empregado. Ele mede impureza dos dados, o quanto aqueles dados estão mais “misturados” em relação às categorias. Quanto mais baixo o coeficiente de Gini após a divisão, mais eficaz é a árvore em separar os dados e tomar decisões melhores.

$$Gini(D) = 1 - \sum_{i=1}^k p_i^2$$

Fórmula do índice de impureza de Gini

- p_i é a proporção de observações com a classe i em relação ao total de observações no nó.
- k é o número de classes.
- D é o conjunto de observações
- Σ : Símbolo de somatório, que percorre todas as observações $i=1$ até k

O Algoritmo CART: Regressão

Em problemas de regressão, a medida de dispersão MSE é utilizada. Ela calcula o erro quadrático médio entre os valores previstos (que em uma árvore de regressão é a média dos valores alvo do nó) e reais.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Fórmula do erro quadrático médio

- n : Número total de observações.
- y_i : Valor real do dado na i -ésima observação
- $\hat{y}_i$: Valor previsto (ou estimado).
- Σ : Símbolo de somatório, que percorre todas as observações $i=1$ até n

O Algoritmo CART

O algoritmo segue uma abordagem recursiva de acordo com os seguintes passos:

- 1. Início:** Começamos com um único nó que representa todo o conjunto de dados de treinamento.
- 2. Divisão:** Para cada atributo, dividir os dados de acordo com um limiar, ou seja, dividir os dados para cada par (atributo, limiar).
- 3. Cálculo do critério:** Para cada par, calcular a função de custo para os dados da esquerda e para os dados da direita e fazer uma média ponderada.

O Algoritmo CART

O algoritmo segue uma abordagem recursiva de acordo os seguintes passos:

- 4. Seleção inteligente:** Selecionar o par (atributo, limiar) que resulta no menor custo e dividir os dados.
- 5. Crescimento recursivo:** Criar nós filhos esquerda e direita e atribuí-los aos diferentes dados divididos e repetir os passos 2 até 5 para cada nó filho (chamar a função recursivamente para cada filho).
- 6. Parada:** Parar quando uma condição de parada for atingida e retornar um aquele nó como um folha.

O Algoritmo CART

Abaixo a fórmula da função de custo ponderada para um nó m :

$$G(D_m, \theta) = \frac{n_m^{left}}{n_m} H(D_m^{left}(\theta)) + \frac{n_m^{right}}{n_m} H(D_m^{right}(\theta))$$

Onde:

- D_m : conjunto de dados total daquele nó.
- θ : limiar ou limite.
- n : número de observações.
- H : função que calcula o custo (Gini ou MSE).

Vantagens x Desvantagens de Árvores de Decisão

VANTAGENS	DESVANTAGENS
✓ Fácil interpretação ✓ Rápida de treinar ✓ Suporta dados heterogêneos ✓ Não requer normalização	✗ Sensível a pequenas variações ✗ Árvores grandes são difíceis de interpretar ✗ Pode sobreajustar

Termos da Árvore de Decisão

Entropy (Entropia)

- Significa: o nível de impureza do nó.
- Função: mede o quanto as amostras de um nó estão misturadas entre as classes.
- Entropia = 0 $\rightarrow$ nó puro (todas as amostras são da mesma classe).
- Entropia alta (~ 1) $\rightarrow$ nó impuro, mistura de classes.

Fórmula:

$$H = -p_1 \log_2(p_1) - p_2 \log_2(p_2)$$

onde p_1, p_2 são as proporções das classes.

Em resumo, Entropy mede o grau de desorganização das classes no nó.

Termos da Árvore de Decisão

Samples (Amostras)

- Significa: número de linhas (exemplos) do conjunto de dados que chegaram até aquele nó.
- Exemplo: samples = 6 → aquele nó representa 6 registros do dataset original.

Em resumo, Samples → quantidade de exemplos representados pelo nó.

Termos da Árvore de Decisão

Value (Valores)

- Significa: distribuição das classes dentro do nó.
- Exemplo: $\text{value} = [4, 2] \rightarrow$ 4 amostras da classe “Não” e 2 da classe “Sim”.
- Isso mostra como estão divididas as amostras nesse ponto da árvore.

Em resumo, Value $\rightarrow$ número de amostras de cada classe no nó.

Termos da Árvore de Decisão

Class (Classe)

- Significa: a classe majoritária (a mais frequente) naquele nó.
- Exemplo: se $\text{value} = [4, 2] \rightarrow \text{class} = \text{Não}$.
- É a decisão final que o nó tomaria se a árvore parasse ali.

Em resumo, Class $\rightarrow$ rótulo mais frequente (decisão do nó).

Exemplos

Exemplo 1: Devo ir à praia?

Situação:

Durante o verão, uma pessoa decide se vai ou não à praia com base nas condições do dia.

Ela considera duas variáveis:

- **Temperatura** (Alta ou Baixa)
- **Chuva** (Sim ou Não)

Com base em experiências anteriores, ela anotou os dias e suas decisões em uma pequena tabela de dados.



Exemplo 2: Classificação (Iris Dataset)

Objetivo → Prever espécie da flor (Setosa, Versicolor, Virginica)

Atributos → comprimento e largura das pétalas e sépalas

iris setosa



petal

sepal

iris versicolor



petal

sepal

iris virginica



petal

sepal

Exemplo 3: Regressão (Preço de Casas)

Objetivo → Prever preço a partir de tamanho e quartos



Transcendence - A Revolução (2014)



Dr. Will Caster, a maior autoridade do mundo em inteligência artificial, está conduzindo experimentos altamente controversos, na intenção de criar um robô com grande variedade de emoções humanas. Quando extremistas antitecnologia tentam matá-lo, Caster convence sua esposa, Evelyn, e seu melhor amigo, Max Waters, a testar seu novo invento nele mesmo. Só que a grande questão não é se eles podem fazer isto, mas se eles devem dar este passo.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679
3. MIENYE, I. D.; JERE, N. A survey of decision trees: concepts, algorithms, and applications. East London: Walter Sisulu University, 2017. Disponível em: <...>. Acesso em: 03 nov. 2025.

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code