



UNINASSAU

CLUSTERING

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

O que é Clustering?

Técnica de Machine Learning não supervisionada para agrupar dados semelhantes em clusters baseado em sua proximidade.

Objetivo

Descobrir estruturas e padrões ocultos em conjuntos de dados sem rótulos pré-definidos.

Conceito Chave

Similaridade e Distância entre os pontos de dados determinam o agrupamento.



Tipos de Clustering

01

PARTICIONAL

- K-Means
- K-Medoids

Divide dados em K clusters não sobrepostos.

02

HIERÁRQUICO

- Aglomerativo
- Divisivo

Cria hierarquia de clusters em dendrograma.

03

DENSIDADE

- DBSCAN
- OPTICS

Agrupa por densidade local de pontos.

K-Means, Hierárquico, DBSCAN


K-Means

Conceito

Algoritmo particional mais popular em clustering.

Ideia Central

Dividir dataset em K clusters, onde cada ponto pertence ao cluster com a média (centroide) mais próxima.



Passos do Algoritmo K-Means

1

Escolher K

Definir o número de clusters K desejado.

2

Inicializar Centroides

Selecionar K centroides aleatoriamente do dataset.

3

Atribuir Pontos

Atribuir cada ponto ao centroide mais próximo (menor distância).

K-Means Clustering

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.datasets import make_blobs

# Gerando dados artificiais com 3 agrupamentos (centros)
X, _ = make_blobs(n_samples=200, centers=3, random_state=42)

# Criando o modelo K-Means com 3 clusters
kmeans = KMeans(n_clusters=3, random_state=42)

# Treinando o modelo e obtendo o rótulo (cluster) de cada ponto
y_kmeans = kmeans.fit_predict(X)


# Plotando os pontos, colorindo conforme o cluster
plt.scatter(X[:, 0], X[:, 1], c=y_kmeans, cmap='viridis')

# Marcando os centróides dos clusters
plt.scatter(kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1],
            s=200, c='red', marker='X', label='Centroides')

plt.title('K-Means Clustering')
plt.legend()
plt.show()
```

- O K-Means tenta dividir os dados em k grupos.
- Cada grupo tem um centróide, e os pontos são atribuídos ao centróide mais próximo.
- O algoritmo recalcula os centróides até a convergência.

K-Means Clustering



K-Means: Vantagens e Desvantagens

+ Vantagens

- Simples e fácil de implementar
- Rápido e eficiente computacionalmente
- Funciona bem com grandes datasets
- Resultados interpretáveis e práticos



- Desvantagens

- K pré-definido antecipadamente
- Sensível a outliers e ruído
- Prefere clusters esféricos
- Dependente da inicialização dos centroides

Clustering Hierárquico

Conceito


Cria uma hierarquia de clusters representada por um dendrograma, mostrando como os dados se agrupam em diferentes níveis de granularidade.

AGLOMERATIVO

Bottom-up: Começa com pontos individuais e os une progressivamente.

DIVISIVO

Top-down: Começa com um cluster e o divide progressivamente.



Métodos de Ligação (Linkage)

1

Single Linkage

Distância mínima entre pontos de clusters diferentes. Une clusters baseado no par de pontos mais próximos.

Exemplo: Se dois clusters têm seus pontos mais próximos a 2 unidades de distância, eles serão unidos.

2

Complete Linkage

Distância máxima entre pontos de clusters diferentes. Une clusters baseado no par de pontos mais distantes.

Exemplo: Considera a maior distância entre qualquer par de pontos nos dois clusters para decisão de fusão.

3

Average Linkage

Distância média entre todos os pares de pontos de clusters diferentes. Abordagem equilibrada entre extremos.

Exemplo: Calcula a média de todas as distâncias entre pontos dos dois clusters para determinar fusão.

Hierárquico: Vantagens e Desvantagens

+ Vantagens

- Sem K pré-definido antecipadamente
- Dendrograma oferece visualização clara
- Mostra hierarquia completa dos dados
- Resultados interpretáveis em múltiplos níveis



- Desvantagens

- Computacionalmente caro ($O(n^2)$ ou $O(n^3)$)
- Difícil lidar com outliers e ruído
- Decisões de fusão são irreversíveis
- Sensível à escolha do método de ligação

Agrupamento Hierárquico (Agglomerative Clustering)

```
from sklearn.cluster import AgglomerativeClustering
import scipy.cluster.hierarchy as sch
import matplotlib.pyplot as plt

# Cria um dendrograma para visualizar o processo de fusão dos clusters
plt.figure(figsize=(6, 4))
sch.dendrogram(sch.linkage(X, method='ward'))
plt.title('Dendrograma - Hierarchical Clustering')
plt.xlabel('Pontos de dados')
plt.ylabel('Distância')
plt.show()

# Cria o modelo de agrupamento hierárquico com 3 clusters
hier = AgglomerativeClustering(n_clusters=3, linkage='ward')

# Treina o modelo e obtém os rótulos dos clusters
y_hier = hier.fit_predict(X)

# Plotando os pontos de dados agrupados
plt.scatter(X[:, 0], X[:, 1], c=y_hier, cmap='plasma')
plt.title('Hierarchical Clustering')
plt.show()
```


- O método hierárquico começa com cada ponto em seu próprio cluster e vai unindo os mais próximos.
- O dendrograma mostra visualmente como os clusters se unem.
- O método 'ward' minimiza a variância dentro dos grupos.

Agrupamento Hierárquico (Agglomerative Clustering)

Dendrograma - Hierarchical Clustering



Hierarchical Clustering




DBSCAN

Conceito

Algoritmo de clustering baseado em densidade que agrupa pontos próximos uns dos outros.

Ideia Central

Agrupa pontos em regiões de alta densidade e marca pontos em regiões de baixa densidade como outliers ou ruído.



Tipos de Pontos em DBSCAN

01

CORE POINT

Ponto com $\geq$ **MinPts** vizinhos dentro do raio ϵ (epsilon).

CARACTERÍSTICAS:

- Forma o núcleo dos clusters
- Sempre pertence a um cluster
- Densidade local alta

02

HIERÁRQUICO

Ponto **próximo** a um Core Point, mas com $<$ **MinPts** vizinhos.

CARACTERÍSTICAS:

- Na borda dos clusters
- Pertence ao cluster do Core Point
- Densidade local média

03

DENSIDADE

Nem Core nem Border Point. Isolado de clusters.

CARACTERÍSTICAS:

- Considerado outlier
- Não pertence a nenhum cluster
- Densidade local muito baixa

DBSCAN: Vantagens e Desvantagens

+ Vantagens

- Não requer K pré-definido
- Descobre clusters de formas arbitrárias
- Robusto a outliers e ruído
- Identifica pontos de ruído naturalmente



- Desvantagens

- Dificuldade com densidades variadas
- Sensível aos parâmetros ϵ e MinPts
- Computacionalmente caro em altas dimensões
- Difícil tuning de parâmetros ideal

DBSCAN (Density-Based Spatial Clustering)

```
from sklearn.cluster import DBSCAN
import matplotlib.pyplot as plt

# Criando o modelo DBSCAN
# eps: raio de vizinhança; min_samples: mínimo de pontos para formar um cluster
dbscan = DBSCAN(eps=0.7, min_samples=5)


# Treina o modelo e obtém os rótulos dos clusters
y_dbscan = dbscan.fit_predict(X)

# Plotando os pontos, coloridos conforme o cluster
# Pontos com rótulo -1 são considerados "outliers" (ruído)
plt.scatter(X[:, 0], X[:, 1], c=y_dbscan, cmap='rainbow')
plt.title('DBSCAN Clustering')
plt.show()
```


- O DBSCAN identifica regiões densas de pontos e as considera clusters.
- Pontos isolados são classificados como ruído (-1).
- É ótimo para clusters de formatos irregulares e com outliers.

DBSCAN (Density-Based Spatial Clustering)

Dendrograma - Hierarchical Clustering



Hierarchical Clustering



Avaliação de Clusters

01 COEFICIENTE DE SILHUETA

DEFINIÇÃO

Mede quão bem um ponto se encaixa em seu próprio cluster comparado com outros clusters.

Interpretação

Varia de -1 a +1:

-1: Ruim

0: Neutro

+1: Ótimo

Uso

Avaliar **qualidade geral** do clustering para qualquer algoritmo.

02 ELBOW METHOD

DEFINIÇÃO

Técnica para encontrar o número K ideal plotando inércia vs. número de clusters.

Interpretação

Procura pelo "cotovelo" (elbow) onde a redução de inércia diminui significativamente.

Uso

Específico para **K-Means** - ajuda a escolher K sem conhecimento prévio.

Aplicações de Clustering

SEGMENTAÇÃO DE CLIENTES

MARKETING E VENDAS

Agrupa clientes por comportamento de compra, preferências e valor monetário para campanhas direcionadas.

Exemplo:

Usar **RFM (Recência, Frequência, Monetário)** para identificar clientes VIP, ativos e inativos.

DETECÇÃO DE ANOMALIAS

Segurança e Finanças

Identifica padrões anormais em transações, comportamentos suspeitos e possíveis fraudes.

Exemplo:

Detectar **transações fraudulentas** que se desviam do padrão normal de compras.

Resumo e Conclusão

K-MEANS

- Rápido e simples
- Requer K pré-definido
- Ótimo para grandes dados
- Clusters esféricos

HIERÁRQUICO

- Rápido e simples
- Requer K pré-definido
- Ótimo para grandes dados
- Clusters esféricos

DBSCAN

- Baseado em densidade
- Formas arbitrárias
- Robusto a outliers
- Parâmetros sensíveis

A escolha do algoritmo de clustering depende da **natureza dos dados, objetivo do problema e recursos computacionais** disponíveis.

Não existe um algoritmo "melhor" universalmente. A eficácia depende da aplicação prática e da qualidade da análise exploratória dos dados.

Segmentação RFM

O que é RFM?

Análise de clientes baseada em três métricas principais:


Recência (R): Há quanto tempo o cliente fez uma compra

Frequência (F): Quantas vezes o cliente comprou

Monetário (M): Quanto o cliente gastou no total

Objetivo

Segmentar clientes em grupos homogêneos para criar estratégias de marketing direcionadas e personalizadas.



Aplicação Prática


Segmentar clientes em grupos homogêneos para criar estratégias de marketing direcionadas e personalizadas.

Atividade Prática

Instruções

- Formar grupos de 3-4 alunos
- Escolher um cenário abaixo (ou propor um novo)

SAÚDE



Agrupamento de pacientes com base em sintomas, histórico médico e resultados de exames para diagnóstico e tratamento personalizado.

- **Problema:** Como agrupar pacientes?
- **Dados:** Sintomas, idade, exames
- **Algoritmo:** K-Means ou Hierárquico?
- **Métrica:** Silhueta ou outra?

FINANÇAS



Deteccção de transações fraudulentas agrupando padrões de comportamento normal e identificando anomalias em dados transacionais.

- **Problema:** Detectar fraudes?
- **Dados:** Transações, valores, locais
- **Algoritmo:** DBSCAN (outliers)?
- **Métrica:** Taxa de detecção?

MÍDIA SOCIAL



Agrupamento de usuários com base em interesses, comportamento de engajamento e conteúdo consumido para recomendações personalizadas.

- **Problema:** Agrupar usuários?
- **Dados:** Interesses, seguidores, posts
- **Algoritmo:** K-Means ou DBSCAN?
- **Métrica:** Coesão intra-cluster?

O Homem Bicentenário (1999)



Longe de uma disputa pelo domínio do mundo, "O Homem Bicentenário" apresenta a IA como o robô doméstico Andrew. Criado para servir a uma família humana, ele possui um comportamento programado, mas com o tempo demonstra criatividade, curiosidade, emoções e consciência — características que vão além do que seria esperado pelos seus programadores.

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679
3. MIENYE, I. D.; JERE, N. A survey of decision trees: concepts, algorithms, and applications. East London: Walter Sisulu University, 2017. Disponível em: <...>. Acesso em: 03 nov. 2025.

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code