



UNINASSAU




Revisão AV2

Análise e Desenvolvimento de Sistemas
Machine Learning
Profº Lindenberg Andrade

Redução de Dimensionalidade

A Maldição da Dimensionalidade


A maldição da dimensionalidade refere-se à relação inversa entre o aumento das dimensões de um modelo e a redução da capacidade de generalização. À medida que o número de variáveis aumenta, o espaço do modelo cresce exponencialmente, tornando os dados esparsos (conjuntos de dados em que a grande maioria dos elementos são zeros ou valores padrão).



O que a Redução da Dimensionalidade?

O que é Redução de Dimensionalidade

Redução de Dimensionalidade é o processo de reduzir o número de variáveis de entrada (atributos) em um conjunto de dados, preservando o máximo possível de informações importantes.




Benefícios da Redução de Dimensionalidade

- **Simplificação de Modelos**

Reduz a complexidade dos modelos de machine learning, tornando-os mais fáceis de entender e interpretar. Modelos mais simples são menos propensos a erros e mais eficientes.

- **Melhoria da Interpretabilidade**

Com menos dimensões, é mais fácil visualizar e compreender os dados. A interpretabilidade é crucial para validar resultados e tomar decisões informadas.




Benefícios da Redução de Dimensionalidade

- **Redução do Tempo de Treinamento**

Menos variáveis significam menos cálculos, resultando em treinamento mais rápido dos algoritmos. Isso é especialmente importante em grandes conjuntos de dados.

- **Mitigação de Overfitting**

Ao remover variáveis redundantes ou ruidosas, a redução de dimensionalidade ajuda a prevenir o superajuste, melhorando a capacidade de generalização do modelo para novos dados.



Features

As **features (ou características)** são as propriedades ou atributos individuais e mensuráveis de um conjunto de dados. Elas são as variáveis de entrada que um modelo usa para aprender padrões e fazer previsões.

The diagram illustrates a data table with four rows and five columns. The columns are labeled 'Size', 'Beds', 'Baths', 'Zip', and 'Price'. The first four columns are grouped under the label 'Features', and the last column is labeled 'Label'. The rows are grouped under the label 'Rows', and the columns are grouped under the label 'Columns'.

Features				Label
Size	Beds	Baths	Zip	Price
1100	1	1	64576	1.29
1900	3	1.5	78321	2.14
2800	3	3	98712	3.10
3400	4	3.5	25721	3.75

Seleção de Features


Tipos de Redução de Dimensionalidade

Seleção de Features

Escolha de um subconjunto das features originais do conjunto de dados, mantendo apenas as variáveis mais relevantes e descartando as demais.

Métodos Principais:

- **Métodos de Filtro:** Avaliam a relevância das features independentemente do modelo
- **Métodos de Wrapper:** Usam o desempenho do modelo para selecionar features
- **Métodos Embarcados:** Seleção integrada ao processo de treinamento do modelo




Métodos de Filtro (Filter Methods)

Os Métodos de Filtro avaliam a relevância das features independentemente do modelo de machine learning. Eles utilizam propriedades intrínsecas das features e medidas estatísticas para classificar e selecionar as features mais relevantes antes do treinamento do modelo.

Como Funciona?

- Os métodos de filtro aplicam testes estatísticos para avaliar a relação entre cada feature e a variável alvo. As features são ranqueadas de acordo com suas pontuações estatísticas, e as features com pontuações mais altas são selecionadas. Este processo ocorre antes do treinamento do modelo, tornando-o muito eficiente.




Métodos de Wrapper

Os métodos wrapper usam o desempenho do modelo para selecionar features. Eles treinam o modelo com diferentes combinações de features e avaliam qual combinação produz o melhor desempenho, considerando as interações entre as features.

Como Funciona?

1. Seleciona um subconjunto de features
2. Treina o modelo com esse subconjunto
3. Avalia o desempenho do modelo
4. Adiciona ou remove features baseado no desempenho
5. Repete até atingir critério de parada




Métodos Embarcados (Embedded Methods)

Os métodos embarcados realizam a seleção de features **durante o processo de treinamento do modelo**. A seleção é integrada ao algoritmo de aprendizado, combinando as vantagens dos métodos de filtro e wrapper.

Diferencial dos Métodos Embarcados:

Ao contrário dos métodos de filtro (que selecionam antes do treinamento) e wrapper (que testam combinações separadamente), os métodos embarcados aprendem quais features contribuem mais para o modelo enquanto o modelo está sendo treinado, tornando o processo mais eficiente.



Extração de Features

Tipos de Redução de Dimensionalidade

Extração de Features

Transformação das features originais em um novo conjunto de features de menor dimensão, criando novas variáveis que capturam a essência dos dados.

Técnicas Principais:


- **PCA (Principal Component Analysis):**
Método linear não supervisionado
- **LDA (Linear Discriminant Analysis):**
Método linear supervisionado
- **t-SNE:** Método não linear para visualização



Tipos de Redução de Dimensionalidade

Extração de Features

No mundo do aprendizado de máquina, a extração de recursos é parte integrante da otimização de modelos — ela gera dados significativos e relevantes, ajudando posteriormente a aumentar a eficiência e a precisão desses modelos.




Análise de Componentes Principais (PCA)

O **PCA (Principal Component Analysis)** é o método de redução de dimensionalidade mais amplamente utilizado. É uma técnica linear de extração de features que combina e transforma as features originais para produzir novas características chamadas componentes principais.

Como Funciona?

- Identifica componentes principais (novas variáveis não correlacionadas)
- Maximiza a variância dos dados projetados
- Realiza transformação linear da matriz de covariância
- Utiliza autovetores e autovalores para determinar os componentes
- Projeta os dados em um novo espaço de menor dimensão



Aplicações Práticas:


Redução de ruído, visualização de dados complexos, pré-processamento para outros algoritmos de machine learning, compressão de imagens e análise exploratória de dados.

Análise Discriminante Linear (LDA)

A **Análise Discriminante Linear (LDA)** é uma técnica linear de extração de features e um método supervisionado. Diferente do PCA, a LDA utiliza os rótulos de classificação para projetar os dados em um novo espaço de menor dimensão.

Objetivo Principal


Maximizar a separação entre classes diferentes enquanto minimiza a variância dentro de cada classe, criando uma representação que facilita a classificação.



Aplicações Práticas:

- Reconhecimento facial
- Diagnóstico médico
- Análise de crédito
- Reconhecimento de padrões

t-SNE (t-distributed Stochastic Neighbor Embedding)



Aplicações:

Visualização de dados complexos, identificação de clusters, exploração de padrões ocultos em conjuntos de dados de alta dimensionalidade, análise exploratória de dados.

O **t-SNE** é um método não linear de redução de dimensionalidade, predominantemente utilizado para visualização de dados complexos de alta dimensão.

Como Funciona:

- Preserva a estrutura local dos dados
- Pontos próximos no espaço original permanecem próximos no espaço reduzido
- Utiliza um kernel Gaussiano para calcular similaridade entre pares de pontos
- Projeta dados para 2 ou 3 dimensões para visualização

Modelos paramétricos e Não paramétricos


Classificação Geral dos Modelos

Tipo de Modelo	Definição	Características Principais	Exemplos Clássicos	Aplicações Comuns
Paramétrico	Assume uma forma funcional fixa para o modelo (ex: linear, polinomial).	- Número fixo de parâmetros. - Menor flexibilidade. - Treinamento rápido. - Requer menos dados.	- Regressão Linear - Regressão Logística - Naive Bayes - Perceptron	- Previsão de preços - Classificação binária simples - Modelos explicáveis
Não Paramétrico	Não assume uma forma fixa; a estrutura do modelo depende dos dados.	- Número de parâmetros aumenta com os dados. - Alta flexibilidade. - Maior custo computacional. - Requer mais dados.	- K-Nearest Neighbors (KNN) - Árvores de Decisão - Random Forest - SVM com kernel não linear	- Classificação complexa - Reconhecimento de padrões - Análise não linear de dados

Modelo Paramétrico

O que é um Modelo Paramétrico?

Um modelo paramétrico é aquele que **assume que a função f tem uma forma funcional predefinida e conhecida**. O trabalho de estimar f é reduzido ao trabalho de estimar um **número fixo de parâmetros (coeficientes)** a partir dos dados de treinamento.



Vantagens e Desvantagens dos Modelos Paramétricos


VANTAGENS

- ✓ Interpretação simples
- ✓ Menos dados necessários
- ✓ Treinamento rápido
- ✓ Boa generalização quando a hipótese é adequada


DESVANTAGENS

- ✗ Estrutura fixa (pouca flexibilidade)
- ✗ Não captura relações complexas
- ✗ Sensível a outliers
- ✗ Risco de underfitting

Exemplos de Modelos Paramétricos




Regressão Linear



Regressão Logística



Naive Bayes




Perceptron

Modelos Não Paramétricos


O que é um Modelo Não Paramétrico?

Um modelo não paramétrico é um tipo de modelo estatístico e de aprendizado de máquina que **não faz suposições rígidas sobre a forma da distribuição dos dados ou sobre um conjunto finito de parâmetros.**



O que é um Modelo Não Paramétrico?

- Não assumem forma funcional.
- Aprendem a estrutura diretamente dos dados.
- A complexidade cresce com o número de amostras.



Vantagens x Desvantagens (Não Paramétricos)

Vantagens e Desvantagens (Não Paramétricos)



Vantagens


- Alta flexibilidade
- Boa capacidade de adaptação




Desvantagens

- Maior custo computacional
- Requerem mais dados
- Sofrem com overfitting

Exemplos de Modelos Não Paramétricos




**KNN (K-Nearest
Neighbors)**



Árvores de Decisão



Random Forest



SVM com kernel

Árvores de decisão

O que são Árvores de Decisão?

Uma Árvore de Decisão é como um caminho de escolhas que nos ajuda a tomar decisões com base em informações. Imagine que você é um médico e tem um paciente. Você quer descobrir se esse paciente está doente ou não. É como um fluxograma de perguntas que você faria para chegar a uma conclusão.




Figura 1. Fluxograma de uma árvore de decisão para decidir se um paciente está doente ou não

Por que usar Árvores de Decisão?

- Fácil interpretação
- Lida bem com variáveis numéricas e categóricas
- Pouco sensível à escala
- Serve como base para ensembles (Random Forest, XGBoost)




Estrutura de uma Árvore

- Nó raiz: primeira divisão
- Nós internos: decisões intermediárias
- Nós Folhas: resultados finais



O Algoritmo CART

O algoritmo de **Classificação e Regressão Baseado em Árvores (CART)** é a base para a construção de árvores de decisão. Ele opera de maneira iterativa, buscando dividir os dados de treinamento em subconjuntos mais homogêneos, refinando as decisões à medida que percorre a estrutura da árvore. Esse algoritmo pode ter várias abordagens que levarão a construir árvores de classificação ou de regressão.



O Algoritmo CART: Classificação

Para tarefas de classificação, o critério de Gini é comumente empregado. Ele mede impureza dos dados, o quanto aqueles dados estão mais “misturados” em relação às categorias. Quanto mais baixo o coeficiente de Gini após a divisão, mais eficaz é a árvore em separar os dados e tomar decisões melhores.

$$Gini(D) = 1 - \sum_{i=1}^k p_i^2$$

Fórmula do índice de impureza de Gini

- p_i é a proporção de observações com a classe i em relação ao total de observações no nó.
- k é o número de classes.
- D é o conjunto de observações
- Σ : Símbolo de somatório, que percorre todas as observações $i=1$ até k

O Algoritmo CART: Regressão

Em problemas de regressão, a medida de dispersão MSE é utilizada. Ela calcula o erro quadrático médio entre os valores previstos (que em uma árvore de regressão é a média dos valores alvo do nó) e reais.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Fórmula do erro quadrático médio

- n : Número total de observações.
- y_i : Valor real do dado na i -ésima observação
- $\hat{y}_i$: Valor previsto (ou estimado).
- Σ : Símbolo de somatório, que percorre todas as observações $i=1$ até n

Vantagens x Desvantagens de Árvores de Decisão

VANTAGENS	DESVANTAGENS
✓ Fácil interpretação ✓ Rápida de treinar ✓ Suporta dados heterogêneos ✓ Não requer normalização	✗ Sensível a pequenas variações ✗ Árvores grandes são difíceis de interpretar ✗ Pode sobreajustar

Clustering

O que é Clustering?

Técnica de Machine Learning não supervisionada para agrupar dados semelhantes em clusters baseado em sua proximidade.

Objetivo

Descobrir estruturas e padrões ocultos em conjuntos de dados sem rótulos pré-definidos.

Conceito Chave

Similaridade e Distância entre os pontos de dados determinam o agrupamento.



Tipos de Clustering

01

PARTICIONAL

- K-Means
- K-Medoids

Divide dados em K clusters não sobrepostos.

02

HIERÁRQUICO

- Aglomerativo
- Divisivo

Cria hierarquia de clusters em dendrograma.

03

DENSIDADE

- DBSCAN
- OPTICS

Agrupa por densidade local de pontos.


K-Means

Conceito

Algoritmo particional mais popular em clustering.

Ideia Central

Dividir dataset em K clusters, onde cada ponto pertence ao cluster com a média (centroide) mais próxima.



Passos do Algoritmo K-Means

1

Escolher K

Definir o número de clusters K desejado.

2

Inicializar Centroides

Selecionar K centroides aleatoriamente do dataset.

3

Atribuir Pontos

Atribuir cada ponto ao centroide mais próximo (menor distância).

K-Means: Vantagens e Desvantagens

+ Vantagens

- Simples e fácil de implementar
- Rápido e eficiente computacionalmente
- Funciona bem com grandes datasets
- Resultados interpretáveis e práticos



- Desvantagens

- K pré-definido antecipadamente
- Sensível a outliers e ruído
- Prefere clusters esféricos
- Dependente da inicialização dos centroides

Clustering Hierárquico

Conceito


Cria uma hierarquia de clusters representada por um dendrograma, mostrando como os dados se agrupam em diferentes níveis de granularidade.

AGLOMERATIVO

Bottom-up: Começa com pontos individuais e os une progressivamente.

DIVISIVO

Top-down: Começa com um cluster e o divide progressivamente.



Métodos de Ligação (Linkage)

1

Single Linkage

Distância mínima entre pontos de clusters diferentes. Une clusters baseado no par de pontos mais próximos.

Exemplo: Se dois clusters têm seus pontos mais próximos a 2 unidades de distância, eles serão unidos.

2

Complete Linkage

Distância máxima entre pontos de clusters diferentes. Une clusters baseado no par de pontos mais distantes.

Exemplo: Considera a maior distância entre qualquer par de pontos nos dois clusters para decisão de fusão.

3

Average Linkage

Distância média entre todos os pares de pontos de clusters diferentes. Abordagem equilibrada entre extremos.

Exemplo: Calcula a média de todas as distâncias entre pontos dos dois clusters para determinar fusão.

Hierárquico: Vantagens e Desvantagens

+ Vantagens

- Sem K pré-definido antecipadamente
- Dendrograma oferece visualização clara
- Mostra hierarquia completa dos dados
- Resultados interpretáveis em múltiplos níveis



- Desvantagens

- Computacionalmente caro ($O(n^2)$ ou $O(n^3)$)
- Difícil lidar com outliers e ruído
- Decisões de fusão são irreversíveis
- Sensível à escolha do método de ligação


DBSCAN

Conceito

Algoritmo de clustering baseado em densidade que agrupa pontos próximos uns dos outros.

Ideia Central

Agrupa pontos em regiões de alta densidade e marca pontos em regiões de baixa densidade como outliers ou ruído.



Tipos de Pontos em DBSCAN

01

CORE POINT

Ponto com $\geq$ **MinPts** vizinhos dentro do raio ϵ (epsilon).

CARACTERÍSTICAS:

- Forma o núcleo dos clusters
- Sempre pertence a um cluster
- Densidade local alta

02

HIERÁRQUICO

Ponto **próximo** a um Core Point, mas com $<$ **MinPts** vizinhos.

CARACTERÍSTICAS:

- Na borda dos clusters
- Pertence ao cluster do Core Point
- Densidade local média

03

DENSIDADE

Nem Core nem Border Point. Isolado de clusters.

CARACTERÍSTICAS:

- Considerado outlier
- Não pertence a nenhum cluster
- Densidade local muito baixa

DBSCAN: Vantagens e Desvantagens

+ Vantagens

- Não requer K pré-definido
- Descobre clusters de formas arbitrárias
- Robusto a outliers e ruído
- Identifica pontos de ruído naturalmente



- Desvantagens

- Dificuldade com densidades variadas
- Sensível aos parâmetros ϵ e MinPts
- Computacionalmente caro em altas dimensões
- Difícil tuning de parâmetros ideal

Resumo e Conclusão

K-MEANS

- Rápido e simples
- Requer K pré-definido
- Ótimo para grandes dados
- Clusters esféricos

HIERÁRQUICO

- Dendrograma visual
- Sem K pré-definido
- Computacionalmente caro
- Hierarquia clara

DBSCAN

- Baseado em densidade
- Formas arbitrárias
- Robusto a outliers
- Parâmetros sensíveis


A escolha do algoritmo de clustering depende da **natureza dos dados, objetivo do problema e recursos computacionais** disponíveis.

Não existe um algoritmo "melhor" universalmente. A eficácia depende da aplicação prática e da qualidade da análise exploratória dos dados.

Perceptron em múltiplas camadas

O que é o Perceptron?

Um perceptron é um algoritmo de aprendizado supervisionado para classificação binária, considerado o modelo mais simples de uma rede neural artificial. Criado por Frank Rosenblatt em 1957, ele funciona como um neurônio artificial que aprende a categorizar dados de entrada em duas classes diferentes (por exemplo, "gato" ou "cachorro") ao encontrar uma "linha de decisão" que separe os dados de forma ideal. É a base para redes neurais mais complexas e pode ser utilizado para tarefas de aprendizado de máquina.



Arquitetura do MLP: Estrutura em Camadas

Entrada


Recebe os dados brutos (features) do problema. Não realiza processamento, apenas distribui os valores para a próxima camada.

Ocultas

Onde o "pensamento" da rede acontece. Cada camada aprende representações progressivamente mais complexas dos dados.

Saída

Produz o resultado final da rede (ex: classificação, regressão, previsão).



Conexões Fully Connected (Densa)

Cada neurônio de uma camada está conectado a todos os neurônios da camada seguinte. Isso permite que cada neurônio receba informações de todos os neurônios anteriores.

Anatomia do Neurônio Artificial

Entradas (Inputs)

Recebe sinais (valores) dos neurônios da camada anterior ou dos dados de entrada. Cada entrada representa uma feature do problema.

Pesos (Weights - w)


Cada conexão de entrada tem um peso associado que determina a importância daquela entrada. Pesos maiores amplificam o sinal; menores o atenuam.

Viés (Bias - b)

Um parâmetro adicional que permite ao neurônio deslocar sua função de ativação. Sem o viés, a rede seria limitada em suas representações.

Função de Ativação (σ)

Função não-linear que decide se o neurônio "dispara". Exemplos: Sigmoid, ReLU, Tanh. Essencial para criar representações complexas.



$$z = (\sum w_i \cdot x_i) + b$$
$$a = \sigma(z)$$

Aplicações Práticas do MLP

CLASSIFICAÇÃO

Reconhecimento de Imagens

Classificação de dígitos escritos à mão (MNIST), reconhecimento de objetos em imagens digitais.

Detecção de Spam

Classificação de e-mails como spam ou legítimos baseado em características do texto.

Análise de Sentimentos

Classificação de textos em redes sociais como positivos, negativos ou neutros.

REGRESSÃO

Previsão de Preços

Estimativa de preços de imóveis, ações ou produtos baseado em características e histórico.

Séries Temporais

Previsão de valores futuros em dados temporais como temperatura, vendas ou tráfego.

Estimativa de Demanda

Previsão de demanda de produtos para otimização de estoque e planejamento.

RECONHECIMENTO DE PADRÕES

Detecção de Anomalias

Identificação de comportamentos anormais em sistemas, transações financeiras ou redes.

Diagnóstico Médico


Análise de exames médicos para detecção de doenças e apoio ao diagnóstico.

Biometria

Reconhecimento facial, impressão digital e autenticação biométrica.

Por Que o MLP é Importante?

O MLP é a **arquitetura fundamental** que permitiu o avanço das Redes Neurais Artificiais. Embora frequentemente substituído por arquiteturas mais especializadas (CNNs para imagens, RNNs para sequências), o MLP permanece **essencial para a compreensão** de como redes neurais aprendem e é ainda amplamente utilizado em muitas aplicações práticas.




Funções de Ativação: Introduzindo a Não-Linearidade

Propósito: Introduzem a não-linearidade. Sem elas, o MLP seria apenas uma série de transformações lineares, equivalente a um Perceptron Simples.

Sigmoide

$$\sigma(z) = 1 / (1 + e^{(-z)})$$

Comprime o valor de saída entre **0 e 1**.
Útil para a camada de saída em problemas de classificação binária.
Historicamente importante, mas menos usada em camadas ocultas.



Funções de Ativação: Introduzindo a Não-Linearidade

ReLU (Rectified Linear Unit)


$$f(x) = \max(0, x)$$

A função mais popular em camadas ocultas. Extremamente **eficiente computacionalmente** e ajuda a mitigar o problema do **vanishing gradient** durante o treinamento.

Tanh (Tangente Hiperbólica)

$$\tanh(z) = (e^z - e^{-z}) / (e^z + e^{-z})$$

Comprime entre **-1 e 1**. Oferece melhor desempenho que Sigmoid em muitos casos, pois é centrada em zero, facilitando o aprendizado.



Backpropagation: O Algoritmo de Ajuste de Pesos


O Conceito

É o método utilizado para calcular a contribuição de **cada peso** no erro total da rede. O erro é propagado **de volta** (backward) da camada de saída para as camadas ocultas, camada por camada.

Cálculo do Gradiente

Utiliza a **Regra da Cadeia** do cálculo para determinar o gradiente (a derivada da função de custo em relação a cada peso).

$$\partial L / \partial w = (\partial L / \partial a) \cdot (\partial a / \partial z) \cdot (\partial z / \partial w)$$



Minority Report (2002)



Essa clássica ficção científica de Steven Spielberg, estrelada por Tom Cruise, retrata um departamento de polícia especializada no ano de 2054 que conta com um sistema que permite que crimes sejam previstos antecipadamente com muita precisão. Isso faz com que a taxa de assassinatos caia para 0.

A trama ganha ares dramáticos quando é previsto um crime de assassinato cometido pelo personagem de Cruise, o detetive John Anderton. Sendo que este é na obra, um dos principais agentes no combate à criminalidade.

Com isso, sua reputação é questionada. Assim como a confiabilidade do sistema. Vale a pena assistir ao filme para ver quem está certo!

REFERÊNCIAS

1. FILHO, Oscar Gabriel. Inteligência Artificial e Aprendizagem de Máquina: aspectos teóricos e aplicações. 1. ed. São Paulo: Edgard Blücher, 2023. 462 p. ISBN 978-65-5506-620-3
2. HUYEN, Chip. Projetando sistemas de Machine Learning: processo iterativo para aplicações prontas para produção. Tradução de Cibelle Ravaglia. 1. ed. São Paulo: Alta Books, 2024. 384 p. ISBN 978-8550819679

Dúvidas?



Profº Lindenberg Andrade
E-mail: linndemberg1@gmail.com



Additional contacts via QR code